INTRODUÇÃO À ESTATÍSTICA

Daniel Takata Gomes

MEDIDAS DE DISPERSÃO

EXEMPLO: SALÁRIO DE PROFESSOR DE MÚSICA

Salário anual hipotético de professores de música na Dinamarca (esquerda) e nos EUA (direita).

EXEMPLO: SALÁRIO DE PROFESSOR DE MÚSICA

Salário anual hipotético de professores de música na Dinamarca (esquerda) e nos EUA (direita).

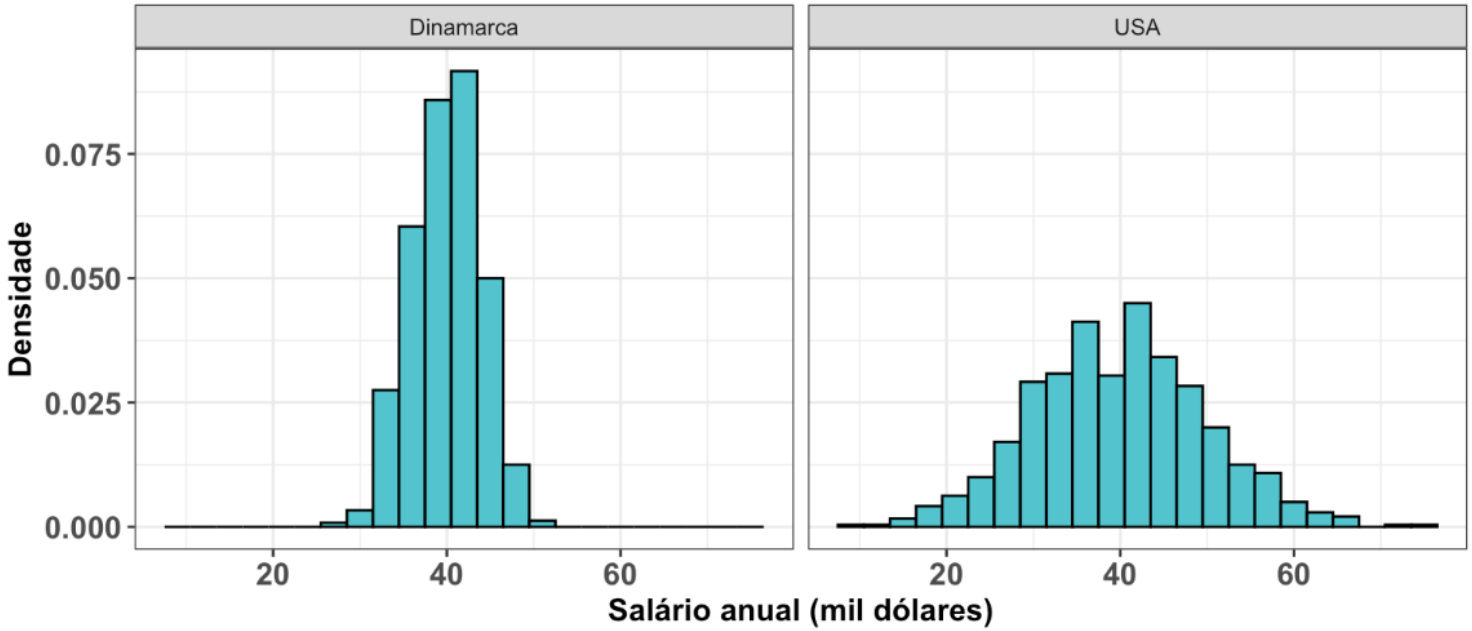

EXEMPLO: SALÁRIO DE PROFESSOR DE MÚSICA

Salário anual hipotético de professores de música na Dinamarca (esquerda) e nos EUA (direita).

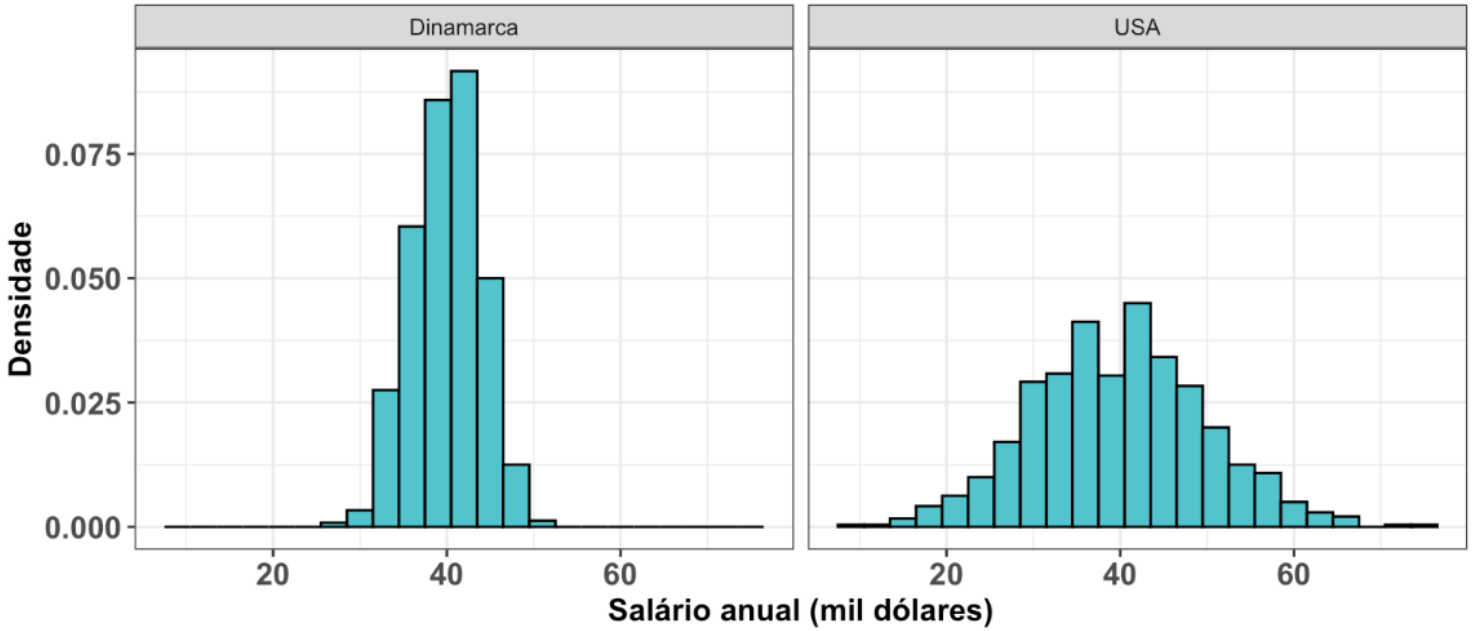

Média salarial Dinamarca: 40.02. Média salarial EUA: 39.87.

AMPLITUDE

- Uma medida de dispersão é **amplitude**: a diferença entre o maior e o menor valor observado na amostra.

AMPLITUDE

- Uma medida de dispersão é **amplitude**: a diferença entre o maior e o menor valor observado na amostra.

- Na Dinamarca:
  - Salários variam de 27 a 52.
  - Amplitude = 52 – 27=25.

AMPLITUDE

- Uma medida de dispersão é **amplitude**: a diferença entre o maior e o menor valor observado na amostra.

- Na Dinamarca:
  - Salários variam de 27 a 52.
  - Amplitude = 52 – 27=25.

- Nos EUA:
  - Salários variam de 9 a 75.
  - Amplitude = 75 – 9 = 66.

AMPLITUDE

- Uma medida de dispersão é **amplitude**: a diferença entre o maior e o menor valor observado na amostra.

- Na Dinamarca:
  - Salários variam de 27 a 52.
  - Amplitude = 52 – 27=25.

- Nos EUA:
  - Salários variam de 9 a 75.
  - Amplitude = 75 – 9 = 66.

Problema com a amplitude: utiliza apenas duas observações (a máxima e a mínima).

MEDIDAS DE DISPERSÃO

- Considere dois conjuntos de dados:

$$A = \{1,2,5,6,6\} \text{ e } B = \{-40,0,5,20,35\}$$

Ambos com média 4 e mediana 5.

MEDIDAS DE DISPERSÃO

- Considere dois conjuntos de dados:

  $A = \{1,2,5,6,6\}$ e $B = \{-40,0,5,20,35\}$

  Ambos com média 4 e mediana 5.

- No entanto, claramente temos que os valores de B são mais dispersos do que em A.

MEDIDAS DE DISPERSÃO

- Considere dois conjuntos de dados:

  $A = \{1,2,5,6,6\}$ e $B = \{-40,0,5,20,35\}$

  Ambos com média 4 e mediana 5.

- No entanto, claramente temos que os valores de B são mais dispersos do que em A.

- Que outra medida podemos usar para considerar essa característica dos dados?

MEDIDAS DE DISPERSÃO

- Podemos observar o quanto as observações estão afastadas de uma determinada medida de posição.

MEDIDAS DE DISPERSÃO

- Podemos observar o quanto as observações estão afastadas de uma determinada medida de posição.

- **Desvio** de uma observação x_i da média $\bar{x}$ é a diferença entre a observação e a média dos dados: $(x_i - \bar{x})$.

MEDIDAS DE DISPERSÃO

- Podemos observar o quanto as observações estão afastadas de uma determinada medida de posição.

- **Desvio** de uma observação x_i da média $\bar{x}$ é a diferença entre a observação e a média dos dados: $(x_i - \bar{x})$.

- O desvio é negativo quando a observação tem valor menor do que a média.

MEDIDAS DE DISPERSÃO

- Podemos observar o quanto as observações estão afastadas de uma determinada medida de posição.

- **Desvio** de uma observação x_i da média $\bar{x}$ é a diferença entre a observação e a média dos dados: $(x_i - \bar{x})$.

- O desvio é negativo quando a observação tem valor menor do que a média.

- O desvio é positivo quando a observação tem valor maior do que a média.

MEDIDAS DE DISPERSÃO

- Estamos interessados nos desvios de todos os pontos x_i's, então poderia-se propor a seguinte medida de dispersão: $\sum_{i=1}^{n}(x_i - \bar{x})$.

MEDIDAS DE DISPERSÃO

- Estamos interessados nos desvios de todos os pontos x_i's, então poderia-se propor a seguinte medida de dispersão: $\sum_{i=1}^{n}(x_i - \bar{x})$.

- Qual o problema?

MEDIDAS DE DISPERSÃO

- Estamos interessados nos desvios de todos os pontos x_i's, então poderia-se propor a seguinte medida de dispersão: $\sum_{i=1}^{n}(x_i - \bar{x})$.

- Qual o problema?

- A média representa o ponto de balanço dos dados, então os desvios irão se contrabalancear, ou seja: $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$.

MEDIDAS DE DISPERSÃO

- Além do mais, uma medida de dispersão em que os desvios positivos e negativos se cancelam não seria útil.

MEDIDAS DE DISPERSÃO

- Além do mais, uma medida de dispersão em que os desvios positivos e negativos se cancelam não seria útil.
- Queremos que se leve em conta cada desvio, independente do sinal.

MEDIDAS DE DISPERSÃO

- Além do mais, uma medida de dispersão em que os desvios positivos e negativos se cancelam não seria útil.
- Queremos que se leve em conta cada desvio, independente do sinal.
- Alternativas:

$$\sum_{i=1}^{n} |\, x_i - \bar{x} \,| \;\; ou \;\; \sum_{i=1}^{n} (\, x_i - \bar{x})^2$$

MEDIDAS DE DISPERSÃO

- Além do mais, uma medida de dispersão em que os desvios positivos e negativos se cancelam não seria útil.
- Queremos que se leve em conta cada desvio, independente do sinal.
- Alternativas:

$$\sum_{i=1}^{n} |\, x_i - \bar{x} \,| \;\; ou \;\; \sum_{i=1}^{n} (\, x_i - \bar{x})^2$$

- Ambas alternativas evitam que desvios iguais em módulo, mas com sinais opostos, se anulem.

MEDIDAS DE DISPERSÃO

- Além do mais, uma medida de dispersão em que os desvios positivos e negativos se cancelam não seria útil.
- Queremos que se leve em conta cada desvio, independente do sinal.
- Alternativas:

$$\sum_{i=1}^{n} |\, x_i - \bar{x} \,| \;\; ou \;\; \sum_{i=1}^{n} (\, x_i - \bar{x})^2$$

- Ambas alternativas evitam que desvios iguais em módulo, mas com sinais opostos, se anulem.
- **Nota**: Veja que $\sum_{i=1}^{n} (\, x_i - \bar{x})^2 = \sum_{i=1}^{n} {x_i}^2 - n\bar{x}$.

VARIÂNCIA E DESVIO PADRÃO

- A média dos desvios ao quadrado é denominada **variância**:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

VARIÂNCIA E DESVIO PADRÃO

- A média dos desvios ao quadrado é denominada **variância**:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

- **Desvio padrão** é a raiz quadrada da variância:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

VARIÂNCIA E DESVIO PADRÃO

- A média dos desvios ao quadrado é denominada **variância**:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

- **Desvio padrão** é a raiz quadrada da variância:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

- **Interpretação**: distância típica entre uma observação e a média dos dados.

VARIÂNCIA E DESVIO PADRÃO

- A média dos desvios ao quadrado é denominada **variância**:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

- **Desvio padrão** é a raiz quadrada da variância:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

- **Interpretação**: distância típica entre uma observação e a média dos dados.
- Quanto maior s, maior a dispersão dos dados.

VARIÂNCIA E DESVIO PADRÃO

- Por que dividir por $n - 1$, e não por n?
- Quando usamos a média da própria amostra, estamos ‘puxando’ os dados para mais perto dela. Isso faz a variabilidade parecer menor do que realmente é. Então dividimos por $n - 1$, e não por n, para corrigir esse efeito.
- Além disso, quando se calcula a média da amostra, “gastamos” uma informação. Temos n dados, mas só $n - 1$ podem variar livremente. O último fica determinado pelos outros.
- Por exemplo, se a média é 10 e já conhecemos $n - 1$ valores, o último é obrigado a ser o que “fecha” a média.
- Ou seja, só existem $n - 1$ desvios independentes.

EXEMPLO A

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	-3	9
2	-2	4
5	1	1
6	2	4
6	2	4

Conjunto de dados A: $\{1,2,5,6,6\}$.

EXEMPLO A

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	-3	9
2	-2	4
5	1	1
6	2	4
6	2	4

Conjunto de dados A: $\{1,2,5,6,6\}$.

A média é $\bar{x} = \frac{20}{5} = 4$.

EXEMPLO A

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	-3	9
2	-2	4
5	1	1
6	2	4
6	2	4

Conjunto de dados A: $\{1,2,5,6,6\}$.

A média é $\bar{x} = \frac{20}{5} = 4$.

Então, a variância é:

$$s^2 = \frac{9 + 4 + 1 + 4 + 4}{5 - 1} = 5.5,$$

EXEMPLO A

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	-3	9
2	-2	4
5	1	1
6	2	4
6	2	4

Conjunto de dados A: $\{1,2,5,6,6\}$.

A média é $\bar{x} = \frac{20}{5} = 4$.

Então, a variância é:

$$s^2 = \frac{9 + 4 + 1 + 4 + 4}{5 - 1} = 5.5,$$

e o desvio padrão:

$$s = \sqrt{s^2} = \sqrt{5.5} = 2.35.$$

EXEMPLO B

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
-40	-44	1936
0	-4	16
5	1	1
20	16	256
35	31	961

Conjunto de dados
$B: \{-40,0,5,20,35\}$.

EXEMPLO B

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
-40	-44	1936
0	-4	16
5	1	1
20	16	256
35	31	961

Conjunto de dados
$B: \{-40,0,5,20,35\}$.
A média é $\bar{x} = \frac{20}{5} = 4$.

EXEMPLO B

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
-40	-44	1936
0	-4	16
5	1	1
20	16	256
35	31	961

Conjunto de dados

$B: \{-40,0,5,20,35\}$.

A média é $\bar{x} = \frac{20}{5} = 4$.

Então, a variância é:

$s^2 = \frac{1936+16+1+256+961}{5-1} = 792.5,$

EXEMPLO B

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
-40	-44	1936
0	-4	16
5	1	1
20	16	256
35	31	961

Conjunto de dados

$B: \{-40,0,5,20,35\}$.

A média é $\bar{x} = \frac{20}{5} = 4$.

Então, a variância é:

$$s^2 = \frac{1936+16+1+256+961}{5-1} = 792.5,$$

e o desvio padrão:

$$s = \sqrt{s^2} = \sqrt{792.5} = 28.15.$$

EXEMPLO: SALÁRIO DE PROFESSOR DE MÚSICA

Salário anual hipotético de professores de música na Dinamarca (esquerda) e nos EUA (direita).

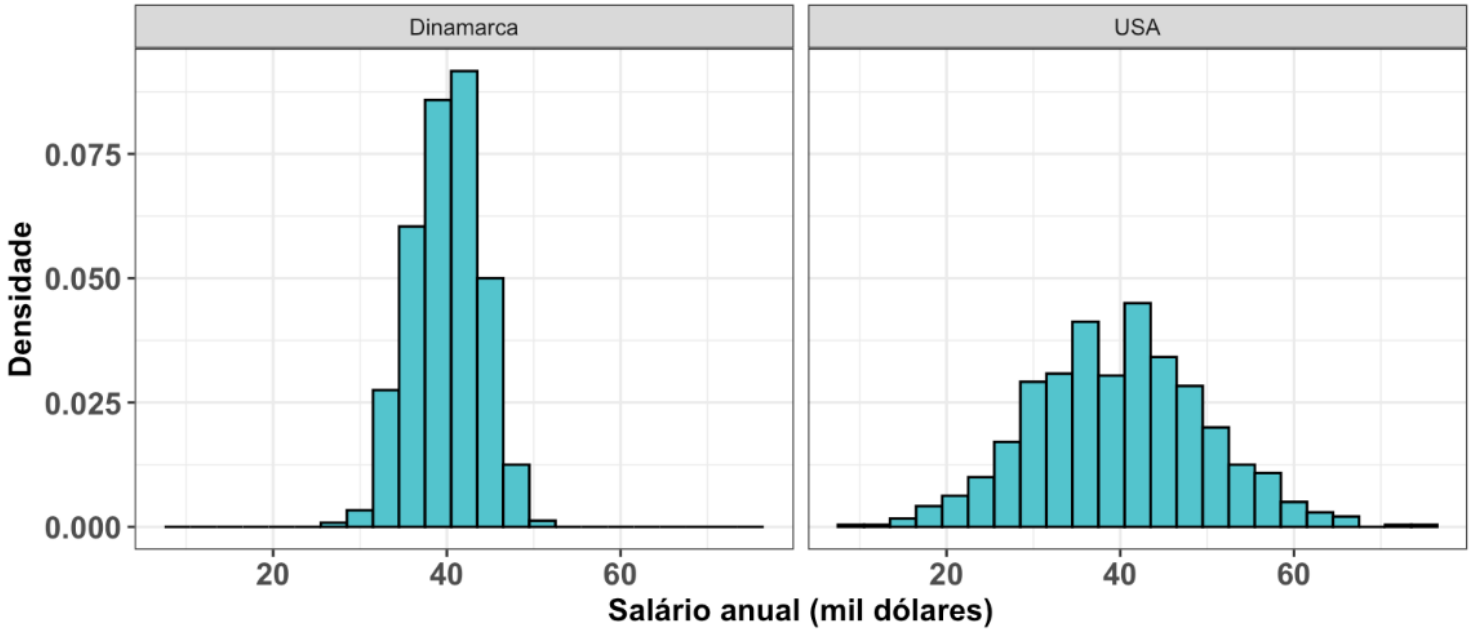

EXEMPLO: SALÁRIO DE PROFESSOR DE MÚSICA

Salário anual hipotético de professores de música na Dinamarca (esquerda) e nos EUA (direita).

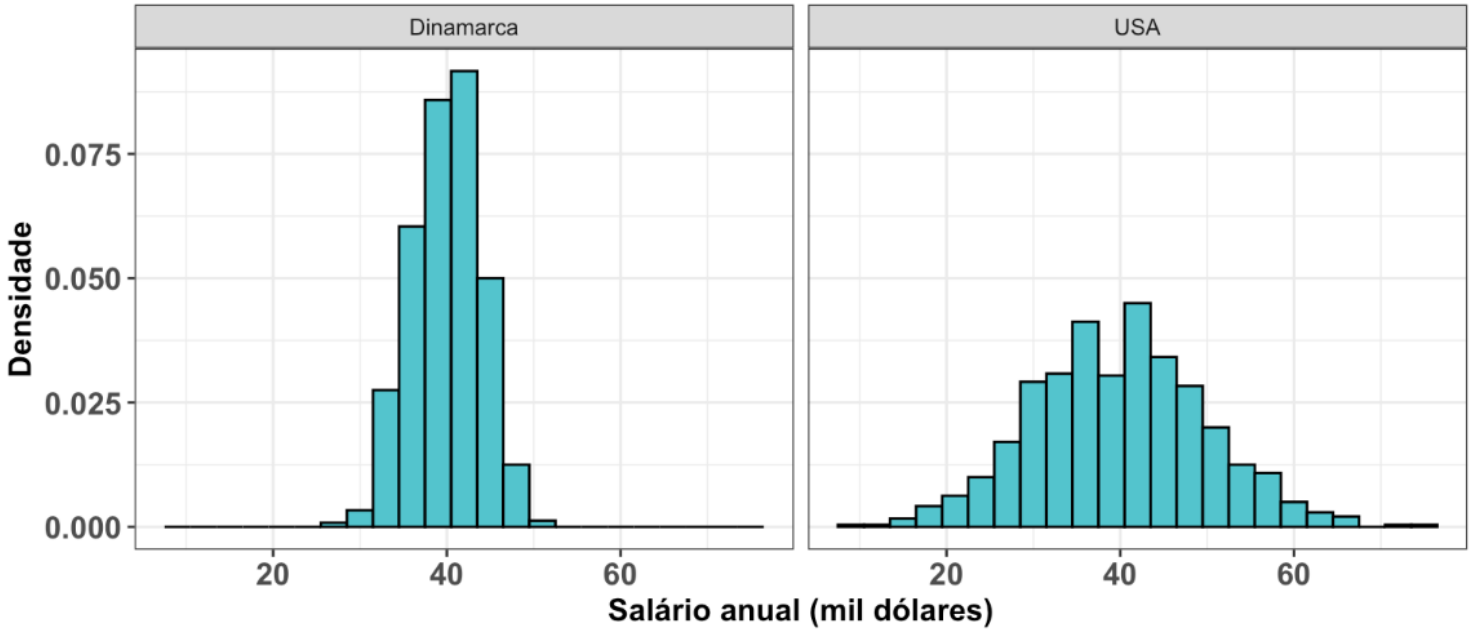

Média salarial Dinamarca: 40.02. Média salarial EUA: 39.87.

EXEMPLO: SALÁRIO DE PROFESSOR DE MÚSICA

Salário anual hipotético de professores de música na Dinamarca (esquerda) e nos EUA (direita).

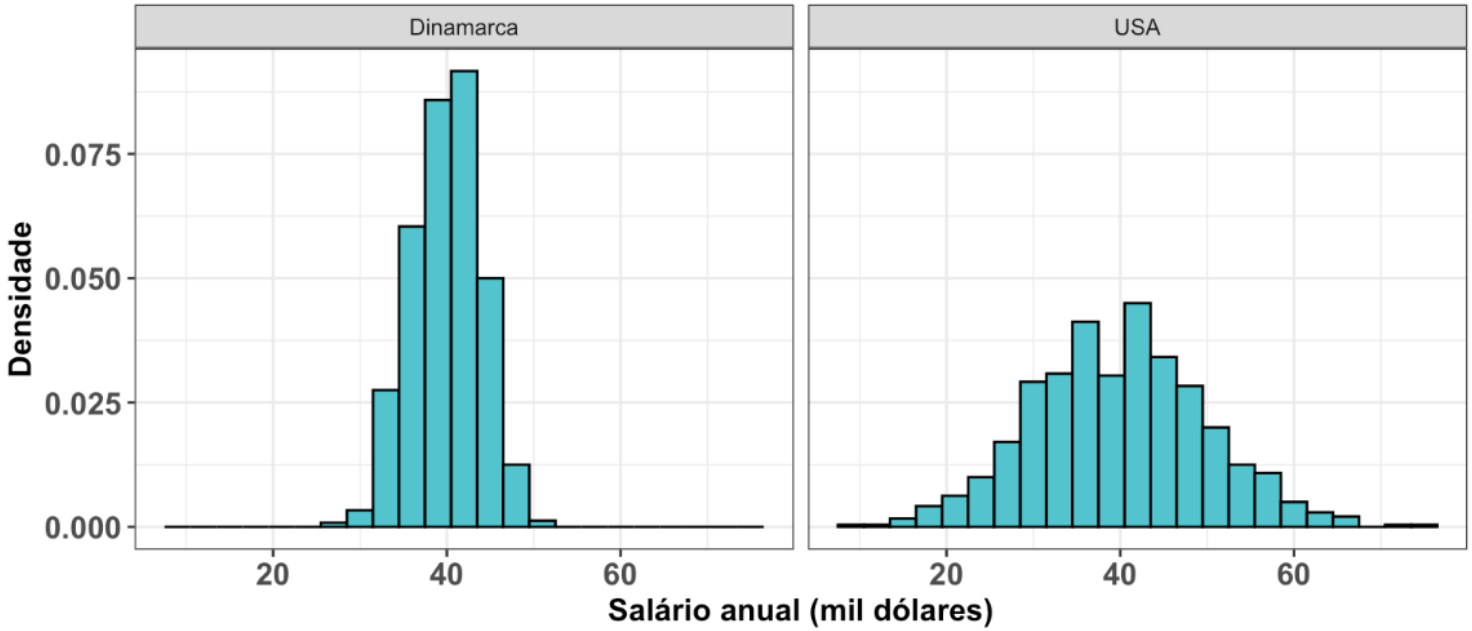

Média salarial Dinamarca: 40.02. Média salarial EUA: 39.87.
Variância na Dinamarca: 15.76. Variância nos EUA: 99.5.

EXEMPLO: NOTAS DE UMA PROVA

- Uma prova aplicada a uma turma de alunos valia 100 pontos. Suponha que a média tenha sido 80.

EXEMPLO: NOTAS DE UMA PROVA

- Uma prova aplicada a uma turma de alunos valia 100 pontos. Suponha que a média tenha sido 80.
- Qual seria um valor plausível para o desvio padrão das notas da classe? s: 0, 10 ou 50?

EXEMPLO: NOTAS DE UMA PROVA

- Uma prova aplicada a uma turma de alunos valia 100 pontos. Suponha que a média tenha sido 80.
- Qual seria um valor plausível para o desvio padrão das notas da classe? s: 0, 10 ou 50?
  - $s = 0$: todos os alunos tiraram a mesma nota.

EXEMPLO: NOTAS DE UMA PROVA

- Uma prova aplicada a uma turma de alunos valia 100 pontos. Suponha que a média tenha sido 80.
- Qual seria um valor plausível para o desvio padrão das notas da classe? s: 0, 10 ou 50?
  - $s = 0$: todos os alunos tiraram a mesma nota.
  - $s = 50$: uma nota típica da classe estaria até 50 pontos distante da média, ou seja, de 30 a 130 pontos.

EXEMPLO: NOTAS DE UMA PROVA

- Uma prova aplicada a uma turma de alunos valia 100 pontos. Suponha que a média tenha sido 80.
- Qual seria um valor plausível para o desvio padrão das notas da classe? s: 0, 10 ou 50?
  - $s = 0$: todos os alunos tiraram a mesma nota.
  - $s = 50$: uma nota típica da classe estaria 50 pontos distante da média, ou seja, de 30 a 130 pontos.
  - $s = 10$: notas típicas seriam de 70 a 90.

COEFICIENTE DE VARIAÇÃO

- Considere a seguinte situação: uma fábrica de ervilhas comercializa seu produto em embalagens de 300 gramas e em embalagens de um quilo.

COEFICIENTE DE VARIAÇÃO

- Considere a seguinte situação: uma fábrica de ervilhas comercializa seu produto em embalagens de 300 gramas e em embalagens de um quilo.

- Para efeitos de controle do processo de enchimento das embalagens, sorteia-se uma amostra de 10 embalagens de cada uma das máquinas de enchimento, obtendo-se os seguintes resultados:

$$300g = \begin{cases} \bar{x} = 295g \\ s = 5g \end{cases} \quad \text{e} \quad 1000g = \begin{cases} \bar{x} = 995g \\ s = 5g \end{cases}.$$

COEFICIENTE DE VARIAÇÃO

- Em qual das duas situações a variabilidade parece ser maior? Ou seja, em qual das duas máquinas parece haver um problema mais sério?

COEFICIENTE DE VARIAÇÃO

- Em qual das duas situações a variabilidade parece ser maior? Ou seja, em qual das duas máquinas parece haver um problema mais sério?

- Note que, em ambos os casos, há uma dispersão de 5 g em torno da média, mas 5 g em 1000 g é menos preocupante do que 5 g em 300 g.

COEFICIENTE DE VARIAÇÃO

- Em qual das duas situações a variabilidade parece ser maior? Ou seja, em qual das duas máquinas parece haver um problema mais sério?

- Note que, em ambos os casos, há uma dispersão de 5 g em torno da média, mas 5 g em 1000 g é menos preocupante do que 5 g em 300 g.

- Como um exemplo mais extremo, um desvio padrão de 10 unidades em um conjunto cuja observação típica é 100 é muito diferente de um desvio padrão de 10 unidades em um conjunto cuja observação típica é 10000.

COEFICIENTE DE VARIAÇÃO

- Surge, assim, a necessidade de uma medida de dispersão relativa, que permita comparar, por exemplo, esses dois conjuntos.

COEFICIENTE DE VARIAÇÃO

- Surge, assim, a necessidade de uma medida de dispersão relativa, que permita comparar, por exemplo, esses dois conjuntos.

- Uma dessas medidas é o coeficiente de variação.

COEFICIENTE DE VARIAÇÃO

- Surge, assim, a necessidade de uma medida de dispersão relativa, que permita comparar, por exemplo, esses dois conjuntos.

- Uma dessas medidas é o coeficiente de variação.

- O coeficiente de variação (CV) é definido por

$$CV = \frac{s}{\bar{x}}.$$

COEFICIENTE DE VARIAÇÃO

- Surge, assim, a necessidade de uma medida de dispersão relativa, que permita comparar, por exemplo, esses dois conjuntos.

- Uma dessas medidas é o coeficiente de variação.

- O coeficiente de variação (CV) é definido por

$$CV = \frac{s}{\bar{x}}.$$

Ou seja, é a razão entre o desvio padrão e sua média.

COEFICIENTE DE VARIAÇÃO

- Surge, assim, a necessidade de uma medida de dispersão relativa, que permita comparar, por exemplo, esses dois conjuntos.

- Uma dessas medidas é o coeficiente de variação.

- O coeficiente de variação (CV) é definido por

$$CV = \frac{s}{\bar{x}}.$$

Ou seja, é a razão entre o desvio padrão e sua média.
Pode ser expresso também em forma de percentual, ou seja,

$$CV = \frac{s}{\bar{x}} \times 100\%.$$

COEFICIENTE DE VARIAÇÃO

- Note que, como o desvio padrão e a média são ambos medidos na mesma unidade dos dados originais, o coeficiente de variação é adimensional.

COEFICIENTE DE VARIAÇÃO

- Note que, como o desvio padrão e a média são ambos medidos na mesma unidade dos dados originais, o coeficiente de variação é adimensional.

- Este fato permite comparações entre conjuntos de dados diferentes, medidos em unidades diferentes.

COEFICIENTE DE VARIAÇÃO

- Note que, como o desvio padrão e a média são ambos medidos na mesma unidade dos dados originais, o coeficiente de variação é adimensional.

- Este fato permite comparações entre conjuntos de dados diferentes, medidos em unidades diferentes.

- No exemplo das latas de ervilha, os coeficientes de variação para as embalagens oriundas das duas máquinas são:

$$300g \rightarrow CV = \frac{5}{295} = 0{,}01695 \quad \text{e} \quad 1000g \rightarrow CV = \frac{5}{995} = 0{,}00502,$$

o que confirma que a variabilidade da máquina de 300g é relativamente maior.