

INTRODUÇÃO À ESTATÍSTICA

Daniel Takata Gomes



RELEMBRANDO: TESTE DE HIPÓTESES

PASSO A PASSO

Passo 1: Suposições



RELEMBRANDO: TESTE DE HIPÓTESES

PASSO A PASSO

Passo 1: Suposições

Passo 2: Hipóteses



RELEMBRANDO: TESTE DE HIPÓTESES

PASSO A PASSO

Passo 1: Suposições

Passo 2: Hipóteses

Passo 3: Estatística do Teste



RELEMBRANDO: TESTE DE HIPÓTESES

PASSO A PASSO

Passo 1: Suposições

Passo 2: Hipóteses

Passo 3: Estatística do Teste

Passo 4: p-valor



RELEMBRANDO: TESTE DE HIPÓTESES

PASSO A PASSO

Passo 1: Suposições

Passo 2: Hipóteses

Passo 3: Estatística do Teste

Passo 4: p-valor

Passo 5: Conclusões



TESTE DE HIPÓTESE PARA UMA PROPORÇÃO

Suponha que temos uma população e uma hipótese sobre a proporção p de indivíduos com certa característica.



TESTE DE HIPÓTESE PARA UMA PROPORÇÃO

Suponha que temos uma população e uma hipótese sobre a proporção p de indivíduos com certa característica.

Hipóteses:

$$H_0: p = p_0 \text{ vs } H_A: \begin{array}{l} p \neq p_0 \text{ (bilateral)} \\ p < p_0 \text{ (unilateral à esquerda)} \\ p > p_0 \text{ (unilateral à direita)} \end{array}$$



TESTE DE HIPÓTESE PARA UMA PROPORÇÃO

Estatística do teste: Baseada na distribuição amostral de $\hat{p}$

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}} \stackrel{H_0}{\sim} N(0, 1)$$



TESTE DE HIPÓTESE PARA UMA PROPORÇÃO

Estatística do teste: Baseada na distribuição amostral de $\hat{p}$

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}} \stackrel{H_0}{\sim} N(0, 1)$$

Condição: $np_0 \geq 10$ e $n(1 - p_0) \geq 10$ para aproximação normal.



TESTE DE HIPÓTESE PARA UMA PROPORÇÃO

p-valor

- $H_A : p \neq p_0$ (bilateral): $\text{p-valor} = P(|Z| \geq |z_{obs}|)$
- $H_A : p < p_0$ (unilateral à esquerda): $\text{p-valor} = P(Z \leq z_{obs})$
- $H_A : p > p_0$ (unilateral à direita): $\text{p-valor} = P(Z \geq z_{obs})$



TESTE DE HIPÓTESE PARA UMA PROPORÇÃO

p-valor

- $H_A : p \neq p_0$ (bilateral): p-valor= $P(|Z| \geq |z_{obs}|)$
- $H_A : p < p_0$ (unilateral à esquerda): p-valor= $P(Z \leq z_{obs})$
- $H_A : p > p_0$ (unilateral à direita): p-valor= $P(Z \geq z_{obs})$

Conclusão: Para um nível de significância α :

- Se p-valor $\leq \alpha$: rejeitamos H_0
- Se p-valor $> \alpha$: não rejeitamos H_0



TESTE DE HIPÓTESE PARA UMA MÉDIA



EXEMPLO

Vamos voltar no problema da máquina que enche pacotes de café. Digamos que o peso nominal do pacote de café seja de 500g. Assume-se que o desvio padrão é conhecido ($\sigma = 10$). Retiraram uma amostra de 25 pacotes e observaram um peso médio de 485g.



EXEMPLO

Vamos voltar no problema da máquina que enche pacotes de café. Digamos que o peso nominal do pacote de café seja de 500g. Assume-se que o desvio padrão é conhecido ($\sigma = 10$). Retiraram uma amostra de 25 pacotes e observaram um peso médio de 485g.

Isso nos traz evidência de que os pacotes têm menos de 500g?



EXEMPLO

Vamos voltar no problema da máquina que enche pacotes de café. Digamos que o peso nominal do pacote de café seja de 500g. Assume-se que o desvio padrão é conhecido ($\sigma = 10$). Retiraram uma amostra de 25 pacotes e observaram um peso médio de 485g.

Isso nos traz evidência de que os pacotes têm menos de 500g?

Já calculamos o IC de 95% para esse problema:

$$IC(\mu, 0.95) = [481.08; 488.92]$$



EXEMPLO

Vamos voltar no problema da máquina que enche pacotes de café. Digamos que o peso nominal do pacote de café seja de 500g. Assume-se que o desvio padrão é conhecido ($\sigma = 10$). Retiraram uma amostra de 25 pacotes e observaram um peso médio de 485g.

Isso nos traz evidência de que os pacotes têm menos de 500g?

Já calculamos o IC de 95% para esse problema:

$$IC(\mu, 0.95) = [481.08; 488.92]$$

Vamos agora testar as hipóteses:

$$H_0: \mu = 500 \text{ vs } H_A: \mu < 500$$



EXEMPLO

Suposições: Seja X_i o peso do i -ésimo pacote de café. Sabemos que $\mathbb{E}(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2$. Coletou-se uma amostra de tamanho $n = 25$. Pelo TCL:

$$\bar{X} \sim N(\mu, \sigma^2/n) \text{ (aprox.)}$$



EXEMPLO

Suposições: Seja X_i o peso do i -ésimo pacote de café. Sabemos que $\mathbb{E}(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2$. Coletou-se uma amostra de tamanho $n = 25$. Pelo TCL:

$$\bar{X} \sim N(\mu, \sigma^2/n) \text{ (aprox.)}$$

Hipóteses: $H_0: \mu = \mu_0 = 500$ vs $H_A: \mu < \mu_0 = 500$



EXEMPLO

Suposições: Seja X_i o peso do i -ésimo pacote de café. Sabemos que $\mathbb{E}(X_i) = \mu$ e $Var(X_i) = \sigma^2$. Coletou-se uma amostra de tamanho $n = 25$. Pelo TCL:

$$\bar{X} \sim N(\mu, \sigma^2/n) \text{ (aprox.)}$$

Hipóteses: $H_0: \mu = \mu_0 = 500$ vs $H_A: \mu < \mu_0 = 500$

Estatística do teste:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \stackrel{H_0}{\sim} N(0, 1)$$



EXEMPLO

Suposições: Seja X_i o peso do i -ésimo pacote de café. Sabemos que $\mathbb{E}(X_i) = \mu$ e $Var(X_i) = \sigma^2$. Coletou-se uma amostra de tamanho $n = 25$. Pelo TCL:

$$\bar{X} \sim N(\mu, \sigma^2/n) \text{ (aprox.)}$$

Hipóteses: $H_0: \mu = \mu_0 = 500$ vs $H_A: \mu < \mu_0 = 500$

Estatística do teste:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \stackrel{H_0}{\sim} N(0, 1)$$

Considerando a amostra obtida:

$$z_{\text{obs}} = \frac{485 - 500}{10/5} = -7.5$$



TESTE DE HIPÓTESES PARA MÉDIA (σ CONHECIDO)

Como medir se -7.5 é evidência contra H_0 ?



TESTE DE HIPÓTESES PARA MÉDIA (σ CONHECIDO)

Como medir se -7.5 é evidência contra H_0 ?

O p-valor é calculado como:

p-valor: $P(Z < -7.5) \approx 0$



TESTE DE HIPÓTESES PARA MÉDIA (σ CONHECIDO)

Como medir se -7.5 é evidência contra H_0 ?

O p-valor é calculado como:

p-valor: $P(Z < -7.5) \approx 0$

Conclusão: Como o p-valor é praticamente zero, rejeitamos H_0 , ou seja, rejeitamos a hipótese de que a média é 500g.



REGIÃO CRÍTICA (REGIÃO DE REJEIÇÃO)

Outra forma de decidirmos se a evidência encontrada nos dados é forte o suficiente para rejeitar H_0 é determinando a **região crítica** ou **região de rejeição**.



REGIÃO CRÍTICA (REGIÃO DE REJEIÇÃO)

Outra forma de decidirmos se a evidência encontrada nos dados é forte o suficiente para rejeitar H_0 é determinando a **região crítica** ou **região de rejeição**.

Região Crítica: conjunto de valores da estatística do teste para os quais a hipótese nula é rejeitada.



REGIÃO CRÍTICA: TESTE UNILATERAL À DIREITA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu > \mu_0$



REGIÃO CRÍTICA: TESTE UNILATERAL À DIREITA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu > \mu_0$


Para um **nível de significância** α , definimos a **região crítica** do teste:



REGIÃO CRÍTICA: TESTE UNILATERAL À DIREITA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu > \mu_0$

Para um **nível de significância** α , definimos a **região crítica** do teste:






REGIÃO CRÍTICA: TESTE UNILATERAL À DIREITA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu > \mu_0$

A região crítica, para $\alpha = 0.05$, é a área em azul na figura:






REGIÃO CRÍTICA: TESTE UNILATERAL À DIREITA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu > \mu_0$

A região crítica, para $\alpha = 0.05$, é a área em azul na figura:



Decisão: Rejeitamos H_0 se $z_{obs} > 1.645$.



REGIÃO CRÍTICA: TESTE UNILATERAL À ESQUERDA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu < \mu_0$

•
•



REGIÃO CRÍTICA: TESTE UNILATERAL À ESQUERDA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu < \mu_0$

Para um **nível de significância** α , definimos a **região crítica** do teste:


:



REGIÃO CRÍTICA: TESTE UNILATERAL À ESQUERDA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu < \mu_0$

Para um **nível de significância** α , definimos a **região crítica** do teste:






REGIÃO CRÍTICA: TESTE UNILATERAL À ESQUERDA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu < \mu_0$

A região crítica, para $\alpha = 0.05$, é a área em azul na figura:






REGIÃO CRÍTICA: TESTE UNILATERAL À ESQUERDA

Hipóteses $H_0: \mu = \mu_0$ vs $H_A: \mu < \mu_0$

A região crítica, para $\alpha = 0.05$, é a área em azul na figura:



Decisão: Rejeitamos H_0 se $z_{obs} < 1.645$.



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

No caso de testar

$$H_0: \mu = \mu_0$$

quando σ é desconhecido e a amostra é pequena ($n < 30$)
devemos utilizar a distribuição t -Student.



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

No caso de testar

$$H_0: \mu = \mu_0 \text{ vs } H_A: \mu \neq \mu_0$$

quando σ é desconhecido e a amostra é pequena ($n < 30$)
devemos utilizar a distribuição t -Student.

Estatística do teste:

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \stackrel{H_0}{\sim} t_{n-1}$$



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

Neste curso, quando σ é desconhecido, vamos nos ater ao caso de amostras maiores ($n > 30$).



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

Neste curso, quando σ é desconhecido, vamos nos ater ao caso de amostras maiores ($n > 30$).

Nesse caso, a exemplo do que fizemos no cálculo de intervalos de confiança, pode-se utilizar a variância amostral s^2 ao invés da variância populacional σ^2 e a mesma estatística de teste do caso σ conhecido.



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

Neste curso, quando σ é desconhecido, vamos nos ater ao caso de amostras maiores ($n > 30$).

Nesse caso, a exemplo do que fizemos no cálculo de intervalos de confiança, pode-se utilizar a variância amostral s^2 ao invés da variância populacional σ^2 e a mesma estatística de teste do caso σ conhecido.

Isso porque, quando n é grande, a distribuição t-Student se aproxima da distribuição normal.



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

No nosso exemplo, suponha que não sabemos o valor de σ , mas o desvio padrão da amostra é $s = 7.1$. Queremos testar



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

No nosso exemplo, suponha que não sabemos o valor de σ , mas o desvio padrão da amostra é $s = 7.1$. Queremos testar

$$H_0: \mu = 500 \text{ vs } H_A: \mu < 500$$

Estatística do teste:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{s/\sqrt{n}} = \frac{485 - 500}{7.1/5} = -10.56$$



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

No nosso exemplo, suponha que não sabemos o valor de σ , mas o desvio padrão da amostra é $s = 7.1$. Queremos testar

$$H_0: \mu = 500 \text{ vs } H_A: \mu < 500$$

Estatística do teste:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{s/\sqrt{n}} = \frac{485 - 500}{7.1/5} = -10.56$$

p-valor: $P(Z < -10.56) \approx 0$



TESTE DE HIPÓTESES PARA MÉDIA (σ DESCONHECIDO)

Conclusão: Rejeitamos a hipótese de que a média é 500g.

Lembrando que, para nível de significância $\alpha = 0.05$, o valor crítico é 1.645. Portanto, se $t_{obs} > t_{crit}$, rejeita-se H_0 .

.



EXEMPLO

41 pacientes obesos, selecionados aleatoriamente, foram submetidos a uma dieta com baixa quantidade de carboidratos.



EXEMPLO

41 pacientes obesos, selecionados aleatoriamente, foram submetidos a uma dieta com baixa quantidade de carboidratos.

Pesquisadores responsáveis pelo estudo acreditam que essa dieta faz com que os pacientes apresentem uma redução de peso.



EXEMPLO

41 pacientes obesos, selecionados aleatoriamente, foram submetidos a uma dieta com baixa quantidade de carboidratos.

Pesquisadores responsáveis pelo estudo acreditam que essa dieta faz com que os pacientes apresentem uma redução de peso.

Após 16 semanas, a diferença média de peso foi -9.7kg , com desvio padrão 3.4 kg .



EXEMPLO

41 pacientes obesos, selecionados aleatoriamente, foram submetidos a uma dieta com baixa quantidade de carboidratos.

Pesquisadores responsáveis pelo estudo acreditam que essa dieta faz com que os pacientes apresentem uma redução de peso.

Após 16 semanas, a diferença média de peso foi -9.7kg , com desvio padrão 3.4 kg .

O que podemos concluir deste estudo?



EXEMPLO

41 pacientes obesos, selecionados aleatoriamente, foram submetidos a uma dieta com baixa quantidade de carboidratos.

Pesquisadores responsáveis pelo estudo acreditam que essa dieta faz com que os pacientes apresentem uma redução de peso.

Após 16 semanas, a diferença média de peso foi -9.7kg , com desvio padrão 3.4 kg.

O que podemos concluir deste estudo?

Detalhes do estudo: *Effect of 6-month adherence to a very low carbohydrate diet program.*



EXEMPLO

Suposições: X_i é a diferença entre peso inicial e final do i -ésimo obeso.

Sabemos que $\mathbb{E}(X_i) = \mu$ e $Var(X_i) = \sigma^2$.

Coletou-se uma amostra de tamanho $n = 41$.

Pelo TCL: $\bar{X} \sim N(\mu, \sigma^2/n)$



EXEMPLO

Suposições: X_i é a diferença entre peso inicial e final do i -ésimo obeso.

Sabemos que $\mathbb{E}(X_i) = \mu$ e $\text{Var}(X_i) = \sigma^2$.

Coletou-se uma amostra de tamanho $n = 41$.

Pelo TCL: $\bar{X} \sim N(\mu, \sigma^2/n)$

Hipóteses: $H_0: \mu = 0$ vs $H_A: \mu < 0$

Ou seja, estamos testando se não há diferença no peso após a dieta versus a hipótese que há redução no peso após a dieta.



EXEMPLO

Estatística do teste: Como $n = 41$, podemos usar a aproximação normal

$$Z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{s/\sqrt{n}} = \frac{-9.7 - 0}{3.4/\sqrt{41}} = -18.3$$



EXEMPLO

Estatística do teste: Como $n = 41$, podemos usar a aproximação normal

$$Z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{s/\sqrt{n}} = \frac{-9.7 - 0}{3.4/\sqrt{41}} = -18.3$$

p-valor: Como o teste é unilateral à esquerda

$$p\text{-valor} = P(Z < -18.3) \approx 0$$



EXEMPLO

Estatística do teste: Como $n = 41$, podemos usar a aproximação normal

$$Z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{s/\sqrt{n}} = \frac{-9.7 - 0}{3.4/\sqrt{41}} = -18.3$$

p-valor: Como o teste é unilateral à esquerda

$$p\text{-valor} = P(Z < -18.3) \approx 0$$

Conclusão: Como o p-valor é bem pequeno (< 0.05) rejeitamos H_0 , ou seja, rejeitamos a hipótese de que a dieta não produz diferença no peso.



EXEMPLO

A associação dos proprietários de indústrias metalúrgicas está muito preocupada com o tempo perdido com acidentes de trabalho, cuja média, nos últimos tempos, tem sido da ordem de 60 horas/homem por ano e desvio padrão de 20 horas/homem.



EXEMPLO

A associação dos proprietários de indústrias metalúrgicas está muito preocupada com o tempo perdido com acidentes de trabalho, cuja média, nos últimos tempos, tem sido da ordem de 60 horas/homem por ano e desvio padrão de 20 horas/homem.

Tentou-se um programa de prevenção de acidentes, após o qual foi tomada uma amostra de nove indústrias e medido o número de horas/homens perdidos por acidentes, que foi de 50 horas.



EXEMPLO

A associação dos proprietários de indústrias metalúrgicas está muito preocupada com o tempo perdido com acidentes de trabalho, cuja média, nos últimos tempos, tem sido da ordem de 60 horas/homem por ano e desvio padrão de 20 horas/homem.

Tentou-se um programa de prevenção de acidentes, após o qual foi tomada uma amostra de nove indústrias e medido o número de horas/homens perdidos por acidentes, que foi de 50 horas.

Você diria, a um nível de significância de 5%, que há evidência de melhoria?



EXEMPLO

A associação dos proprietários de indústrias metalúrgicas está muito preocupada com o tempo perdido com acidentes de trabalho, cuja média, nos últimos tempos, tem sido da ordem de 60 horas/homem por ano e desvio padrão de 20 horas/homem.

Tentou-se um programa de prevenção de acidentes, após o qual foi tomada uma amostra de nove indústrias e medido o número de horas/homens perdidos por acidentes, que foi de 50 horas.

Você diria, a um nível de significância de 5%, que há evidência de melhoria?

Fonte: Morettin & Bussab, Estatística Básica 5^a edição, pág. 334.



EXEMPLO

Queremos testar a hipótese que μ , o número médio de horas perdidas com acidentes de trabalho, tenha permanecido o mesmo. Ou seja,

$$H_0: \mu = 60 \text{ vs } H_A: \mu < 60$$



EXEMPLO

Queremos testar a hipótese que μ , o número médio de horas perdidas com acidentes de trabalho, tenha permanecido o mesmo. Ou seja,

$$H_0: \mu = 60 \text{ vs } H_A: \mu < 60$$

Estatística do teste:

$$z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{\sigma/\sqrt{n}} = \frac{50 - 60}{20/3} = -1.5$$



EXEMPLO

Queremos testar a hipótese que μ , o número médio de horas perdidas com acidentes de trabalho, tenha permanecido o mesmo. Ou seja,

$$H_0: \mu = 60 \text{ vs } H_A: \mu < 60$$

Estatística do teste:

$$Z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{\sigma/\sqrt{n}} = \frac{50 - 60}{20/3} = -1.5$$

p-valor: $P(Z \leq -1.5) = 0.067$



EXEMPLO

Queremos testar a hipótese que μ , o número médio de horas perdidas com acidentes de trabalho, tenha permanecido o mesmo. Ou seja,

$$H_0: \mu = 60 \text{ vs } H_A: \mu < 60$$

Estatística do teste:

$$Z_{obs} = \frac{\bar{x}_{obs} - \mu_0}{\sigma/\sqrt{n}} = \frac{50 - 60}{20/3} = -1.5$$

p-valor: $P(Z \leq -1.5) = 0.067$

Conclusão: Como o p-valor é maior que 0.05, não rejeitamos a hipótese de que a média é 60. Ou seja, não há evidência contra da hipótese de que o número médio de horas perdidas tenha se mantido o mesmo.



EXEMPLO

Podemos também determinar a região crítica.



EXEMPLO

Podemos também determinar a região crítica.


Como temos um teste unilateral à esquerda, para um nível de significância de 5%, rejeitamos H_0 se $z_{obs} < -z_{0.05} = -1.645$.



EXEMPLO

Podemos também determinar a região crítica.

Como temos um teste unilateral à esquerda, para um nível de significância de 5%, rejeitamos H_0 se $z_{obs} < -z_{0.05} = -1.645$.






EXEMPLO

Podemos também determinar a região crítica.

Como temos um teste unilateral à esquerda, para um nível de significância de 5%, rejeitamos H_0 se $z_{obs} < -z_{0.05} = -1.645$.



Como $z_{obs} = -1.5 > -1.645$, então não rejeitamos H_0 .