

INTRODUÇÃO À ESTATÍSTICA

Daniel Takata Gomes



TESTE DE INDEPENDÊNCIA ENTRE VARIÁVEIS QUALITATIVAS



GRAU DE ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Vimos que uma medida usualmente utilizada para avaliar o grau de associação entre variáveis quantitativas é o Coeficiente de Contingência de Pearson, dado por:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + N}}$$



GRAU DE ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Vimos que uma medida usualmente utilizada para avaliar o grau de associação entre variáveis quantitativas é o Coeficiente de Contingência de Pearson, dado por:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + N}}$$

- C pode assumir valores entre zero e um, Quanto mais próximo de um, maior é a associação.



GRAU DE ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

N é o tamanho da amostra;

$$\chi^2 = \sum_i \sum_j \left[\frac{(f_{ij} - e_{ij})^2}{e_{ij}} \right], \text{ onde } i \text{ é a } i\text{-ésima linha e } j \text{ é a } j\text{-ésima coluna;}$$

$$e_{ij} = \frac{\text{total linha } i \times \text{total coluna } j}{N}$$



GRAU DE ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Os valores e_{ij} são os valores esperados considerando que não há associação entre as variáveis.



GRAU DE ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Os valores e_{ij} são os valores esperados considerando que não há associação entre as variáveis.
- Quanto maior o valor de χ^2 , mais distante os valores observados estão desses valores esperados. Ou seja, χ^2 pode ser um indicador de falta de associação entre as variáveis, ou de independência entre as variáveis.



TESTE DE INDEPENDÊNCIA

- A ideia é comparar a distribuição conjunta amostral de X e Y com o produto das respectivas distribuições marginais amostrais.



TESTE DE INDEPENDÊNCIA

- A ideia é comparar a distribuição conjunta amostral de X e Y com o produto das respectivas distribuições marginais amostrais.
- Quanto menor for a distância entre elas, mais fortes serão as razões para se supor que as variáveis X e Y são independentes.



TESTE DE INDEPENDÊNCIA

O interesse é testar:

H_0 : X e Y são independentes

H_1 : Existe associação entre X e Y



TESTE DE INDEPENDÊNCIA

O interesse é testar:

H_0 : *X e Y são independentes*

H_1 : *Existe associação entre X e Y*

Ou seja,

$$H_0 : P(X = a_i, Y = b_j) = P(X = a_i) P(Y = b_j), \quad \text{para todo } i \text{ e } j.$$

$$H_1 : P(X = a_i, Y = b_j) \neq P(X = a_i) P(Y = b_j), \quad \text{para algum par } (i, j).$$



TESTE DE INDEPENDÊNCIA

Valores de X	Valores de Y				Total
	b_1	b_2	...	b_s	
a_1	n_{11}	n_{12}	...	n_{1s}	$n_{1.}$
a_2	n_{21}	n_{22}	...	n_{2s}	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
a_r	n_{r1}	n_{r2}	...	n_{rs}	$n_{r.}$
Total	$n_{.1}$	$n_{.2}$	...	$n_{.s}$	n



TESTE DE INDEPENDÊNCIA

A partir dos dados amostrais, podemos calcular:



TESTE DE INDEPENDÊNCIA

A partir dos dados amostrais, podemos calcular:

Estimativa de $P(X' = a_i \ Y = b_j)$:

$$\frac{n_{ij}}{n}$$



TESTE DE INDEPENDÊNCIA

A partir dos dados amostrais, podemos calcular:

Estimativa de $P(X = a_i, Y = b_j)$:
$$\frac{n_{ij}}{n}$$

Estimativa de $P(X = a_i)$:
$$\frac{n_{i.}}{n}$$



TESTE DE INDEPENDÊNCIA

A partir dos dados amostrais, podemos calcular:

Estimativa de $P(X = a_i, Y = b_j)$:
$$\frac{n_{ij}}{n}$$

Estimativa de $P(X = a_i)$:
$$\frac{n_{i.}}{n}$$

Estimativa de $P(Y = b_j)$:
$$\frac{n_{.j}}{n}$$



TESTE DE INDEPENDÊNCIA

A partir dos dados amostrais, podemos calcular:

Estimativa de $P(X = a_i, Y = b_j)$:
$$\frac{n_{ij}}{n}$$

Estimativa de $P(X = a_i)$:
$$\frac{n_{i.}}{n}$$

Estimativa de $P(Y = b_j)$:
$$\frac{n_{.j}}{n}$$

Portanto, se H_0 é verdadeira,

$$P(X = a_i, Y = b_j) = P(X = a_i) P(Y = b_j).$$



TESTE DE INDEPENDÊNCIA

Ou seja,

$$\frac{n_{ij}}{n} \approx \frac{n_{i.}}{n} \times \frac{n_{.j}}{n}.$$



TESTE DE INDEPENDÊNCIA

Ou seja,

$$\frac{n_{ij}}{n} \approx \frac{n_{i.}}{n} \times \frac{n_{.j}}{n}.$$

Multiplicando ambos os lados por n , obtemos

$$n_{ij} \approx \frac{n_{i.} \cdot n_{.j}}{n}.$$



TESTE DE INDEPENDÊNCIA

Ou seja,

$$\frac{n_{ij}}{n} \approx \frac{n_{i.}}{n} \times \frac{n_{.j}}{n}.$$

Multiplicando ambos os lados por n , obtemos

$$n_{ij} \approx \frac{n_{i.} \cdot n_{.j}}{n}.$$

Assim,

$$\frac{n_{i.} \cdot n_{.j}}{n}$$

é a frequência esperada de ocorrências na posição (i, j) da tabela, quando há independência entre X e Y .



TESTE DE INDEPENDÊNCIA

Define-se

$$e_{ij} = \frac{n_{i.} n_{.j}}{n}.$$



TESTE DE INDEPENDÊNCIA

Define-se

$$e_{ij} = \frac{n_{i.} n_{.j}}{n}.$$

Por outro lado, por definição, n_{ij} é a frequência observada quando $X = a_i$ e $Y = b_j$.



TESTE DE INDEPENDÊNCIA

Define-se

$$e_{ij} = \frac{n_{i.} n_{.j}}{n}.$$

Por outro lado, por definição, n_{ij} é a frequência observada quando $X = a_i$ e $Y = b_j$.

A estatística de teste é

$$\chi^2_{obs} = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - e_{ij})^2}{e_{ij}}.$$




TESTE DE INDEPENDÊNCIA

- Pode-se provar que, se H_0 é verdadeira, a distribuição dessa estatística aproxima-se cada vez mais de uma distribuição qui-quadrado com $(r - 1)(s - 1)$ graus de liberdade, à medida que o tamanho da amostra n aumenta.



TESTE DE INDEPENDÊNCIA





TESTE DE INDEPENDÊNCIA

Dado o nível de significância α , o critério de decisão é:



TESTE DE INDEPENDÊNCIA

Dado o nível de significância α , o critério de decisão é:

Rejeitar H_0 se

$$\chi_{obs}^2 > \chi_{1-\alpha}^2,$$



TESTE DE INDEPENDÊNCIA

Dado o nível de significância α , o critério de decisão é:

Rejeitar H_0 se

$$\chi_{obs}^2 > \chi_{1-\alpha}^2,$$

em que

$$\chi_{1-\alpha}^2$$

é o quantil de ordem $1 - \alpha$ da distribuição qui-quadrado com $(r - 1)(s - 1)$ graus de liberdade.



TESTE DE INDEPENDÊNCIA

Esse teste é conhecido como **teste qui-quadrado de Pearson**.



TESTE DE INDEPENDÊNCIA

Valores de referência da distribuição qui-quadrado para $\alpha = 0,05$:

Graus de liberdade	Valor de referência	Graus de liberdade	Valor de referência
1	3.841	11	19.675
2	5.991	12	21.026
3	7.815	13	22.362
4	9.488	14	23.685
5	11.07	15	24.996
6	12.592	16	26.296
7	14.067	17	27.587
8	15.507	18	28.869
9	16.919	19	30.144
10	18.307	20	31.41



EXEMPLO

Exemplo: Tabela de dupla entrada com as variáveis *procedência* e *grau de instrução*.

Procedência (X)	Grau de Instrução (Y)			Total
	Fundamental	Médio	Superior	
Capital	4	5	2	11
Interior	3	7	2	12
Outra	5	6	2	13
Total	12	18	6	36



EXEMPLO

Hipóteses:

H_0 : as variáveis Procedência e Grau de Instrução são independentes

H_1 : existe associação entre as variáveis



EXEMPLO

Tabela de valores esperados sob independência:

Procedência (X)	Grau de Instrução (Y)			Total
	Fundamental	Médio	Superior	
Capital	3.67	5.5	1.83	11
Interior	4	6	2	12
Outra	4.33	6.5	2.17	13
Total	12	18	6	36



EXEMPLO

Cálculo da estatística de teste:

Procedência (X)	Grau de Instrução (Y)			Total
	Fundamental	Médio	Superior	
Capital	0.03	0.05	0.02	
Interior	0.25	0.17	0	
Outra	0.10	0.04	0.01	
Total				



EXEMPLO

- $\chi^2_{obs} = 0,66$



EXEMPLO

- $\chi^2_{obs} = 0,66$
- É um valor alto o suficiente para desconfiarmos da validade de H_0 ?



EXEMPLO

- $\chi^2_{obs} = 0,66$
- É um valor alto o suficiente para desconfiarmos da validade de H_0 ?
- Precisamos ter o valor de referência da distribuição qui-quadrado com 4 graus de liberdade (pois $r = 3$ e $s = 3$).



EXEMPLO

- Para quatro graus de liberdade, o valor de referência é 9,488.



EXEMPLO

- Para quatro graus de liberdade, o valor de referência é 9,488.
- Como $\chi^2_{obs} = 0,66 < 9,488$, então o p -valor é maior que 5%. Logo, não se rejeita H_0 , ou seja, não há evidência para rejeitar a hipótese de que as variáveis são independentes.



EXEMPLO

Exemplo dos dados de alunos Física e Ciências Sociais e suas distribuições por sexo:

Sexo (X)	Carreira (Y)		Total
	Física	Ciências Sociais	
Masculino	100	40	140
Feminino	20	40	60
Total	120	80	200



EXEMPLO

Hipóteses:

H_0 : as variáveis Sexo e Carreira são independentes

H_1 : existe associação entre as variáveis



EXEMPLO

Valores esperados:

Sexo (X)	Carreira (Y)		Total
	Física	Ciências Sociais	
Masculino	84	56	140
Feminino	36	24	60
Total	120	80	200



EXEMPLO

- Valor da estatística χ^2_{obs} : $3,04 + 4,57 + 7,11 + 10,67 = 25,40$.



EXEMPLO

- Valor da estatística χ^2_{obs} : $3,04 + 4,57 + 7,11 + 10,67 = 25,40$.
- Para um grau de liberdade (pois $r = 2$ e $s = 2$), o valor de referência é 3,84.



EXEMPLO

- Valor da estatística $\chi^2_{obs} : 3,04 + 4,57 + 7,11 + 10,67 = 25,40$.
- Para um grau de liberdade (pois $r = 2$ e $s = 2$), o valor de referência é 3,84.
- Como $\chi^2_{obs} = 25,40 > 3,84$, então o p -valor é menor que 5%. Logo, rejeita-se H_0 , ou seja, há evidência para rejeitar a hipótese de que as variáveis são independentes.