

INTRODUÇÃO À ESTATÍSTICA

Daniel Takata Gomes



ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS



ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Muitas vezes estamos interessados em avaliar o relacionamento entre variáveis quantitativas sejam elas discretas ou contínuas.
- Basicamente dois tipos de análise podem ser realizados
 - Análise de correlação
 - Análise de regressão
- Na análise de correlação e regressão há interesse em verificar se e como duas variáveis quantitativas relacionam se entre si em uma população.



ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- A análise de correlação fornece um número que resume o relacionamento entre as variáveis, indicando a força e a direção do relacionamento.
- A análise de regressão fornece uma equação matemática que descreve a natureza do relacionamento entre as duas variáveis, permitindo inclusive que sejam feitas previsões dos valores de uma delas em função dos valores das outras.
- Quando há apenas duas variáveis envolvidas a análise de regressão é chamada simples Quando há mais de duas variáveis temos a análise de regressão múltipla.



ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Uma das suposições básicas da análise de correlação e regressão é que há alguma teoria (ou evidência empírica) que permita levantar hipóteses sobre a relação de dependência entre as variáveis.
- Ou seja, que permita identificar variáveis dependente e independente(s).
- A teoria deve mostrar se esperamos associação positiva ou negativa e em que grau.




ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Para que seja possível realizar uma análise de correlação e/ou regressão, os dados devem provir de observações emparelhadas e em condições semelhantes.
- Se estamos avaliando a correlação existente entre a altura e o peso de um determinado grupo de crianças, por exemplo, o peso de uma determinada criança deve ser medido e registrado no mesmo instante em que é medida e registrada a sua altura.



ASSOCIAÇÃO ENTRE VARIÁVEIS QUANTITATIVAS

- Se estamos analisando duas variáveis quantitativas, cujas observações constituem pares ordenados, chamando estas variáveis de X e Y podemos exibir o conjunto de pares ordenado (x,y) em um diagrama cartesiano, que é chamado de diagrama de dispersão.





COEFICIENTE DE CORRELAÇÃO

- Através do diagrama de dispersão é possível identificar se existe alguma associação entre as variáveis e se essa associação é linear ou não.
- Iremos definir uma medida que avalia o quanto a nuvem de pontos no gráfico de dispersão aproxima-se de uma reta e esta medida será definida de modo a variar em um intervalo de -1 a 1 .
- Esta medida numérica que mede o grau de associação entre duas variáveis e também da proximidade dos dados a uma reta é denominada coeficiente de correlação linear.



COEFICIENTE DE CORRELAÇÃO

- Dados n pares de valores $(X_1, Y_1), \dots, (X_n, Y_n)$, então o coeficiente de correlação linear de Pearson é definido por

$$r(x, y) = \frac{1}{n} \sum_{i=1}^n \frac{(X_i - \bar{X})(Y_i - \bar{Y})}{dp(X)dp(Y)},$$

em que $\bar{X}$ e $dp(X)$ são a média e o desvio padrão amostrais da variável X , respectivamente, e $\bar{Y}$ e $dp(Y)$ são a média e o desvio padrão amostrais da variável Y , respectivamente.



COEFICIENTE DE CORRELAÇÃO


Calcule o coeficiente de correlação entre as variáveis número de anos de experiência de um agente de seguros e seu respectivo número de clientes.

Agente	Anos	Clientes
A	2	48
B	3	50
C	4	56
D	5	52
E	4	43
F	6	60
G	7	62
H	8	58
I	8	64
J	10	72



COEFICIENTE DE CORRELAÇÃO

Gráfico de dispersão:



Agente	Anos	Clientes
A	2	48
B	3	50
C	4	56
D	5	52
E	4	43
F	6	60
G	7	62
H	8	58
I	8	64
J	10	72



COEFICIENTE DE CORRELAÇÃO

Coeficiente de correlação:

$$r(x,y) = 0,789$$

Agente	Anos	Clientes
A	2	48
B	3	50
C	4	56
D	5	52
E	4	43
F	6	60
G	7	62
H	8	58
I	8	64
J	10	72



COEFICIENTE DE CORRELAÇÃO

- Valores de $r(x,y)$ positivos indicam uma relação positiva entre as variáveis (quando uma cresce, a outra cresce).
- Valores de $r(x,y)$ negativos indicam uma relação negativa entre as variáveis (quando uma cresce, a outra decresce).
- Um valor em módulo maior que 0,7 ou 0,8 em geral indica uma relação linear forte entre as variáveis.



ANÁLISE DE REGRESSÃO

- Em alguns casos, duas variáveis se relacionam de uma maneira determinística o que significa que, dado um valor de uma variável, o valor da outra variável fica automaticamente determinado sem qualquer erro.
- Aqui estamos interessados em modelos probabilísticos o que significa que uma variável não é completamente determinada pela outra variável.



ANÁLISE DE REGRESSÃO

- A equação de regressão expressa uma relação entre X (variável explicativa ou independente) e Y (variável resposta ou dependente).
- A equação típica de uma reta de regressão é expressa na forma

$$Y = \beta_0 + \beta_1 X,$$

em que β_0 é o intercepto e β_1 é a inclinação da reta.

- β_0 e β_1 são parâmetros e estatísticas são usadas para estimá-los.



ANÁLISE DE REGRESSÃO

- As estimativas serão denotadas por

$$\hat{y} = b_0 + b_1x.$$

- A reta de regressão também é chamada de reta de mínimos quadrados.
- As estimativas dos parâmetros são encontradas através das seguintes fórmulas:

$$b_0 = \bar{y} - b_1\bar{x};$$

$$b_1 = \frac{n \sum_{i=1}^n x_i y_i - (\sum_{i=1}^n x_i)(\sum_{i=1}^n y_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}.$$



ANÁLISE DE REGRESSÃO

- Uma vez calculados b_0 e b_1 podemos identificar a equação estimada de regressão, que tem a seguinte propriedade a reta de regressão é a que melhor se ajusta aos dados amostrais.
- Podemos usar a reta de regressão para ver o efeito sobre uma variável quando a outra variável muda por uma determinada quantidade.
- b_0 é o ponto onde a reta corta o eixo das ordenadas.
- b_1 representa o quanto varia a média de Y para o aumento de uma unidade da variável X .



ANÁLISE DE REGRESSÃO

Use os dados amostrais para encontrar a reta de regressão.

X	Y
3	5
1	8
3	6
5	4
6	2



ANÁLISE DE REGRESSÃO

Coeficiente de correlação:

$$r(x,y) = -0,975$$

Esse valor indica uma forte relação negativa entre as duas variáveis.

X	Y
3	5
1	8
3	6
5	4
6	2



ANÁLISE DE REGRESSÃO

X	Y	X²	XY
3	5	9	15
1	8	1	8
3	6	9	18
5	4	25	20
6	2	36	12

$$\sum_{i=1}^5 x_i = 18$$

$$\sum_{i=1}^5 y_i = 25$$

$$\sum_{i=1}^5 x_i^2 = 80$$

$$\sum_{i=1}^5 x_i y_i = 73$$

$$\bar{x} = 3,6$$

$$\bar{y} = 5$$



ANÁLISE DE REGRESSÃO


$$b_1 = \frac{n \sum_{i=1}^n x_i y_i - (\sum_{i=1}^n x_i)(\sum_{i=1}^n y_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} = \frac{5 \times 73 - 18 \times 25}{5 \times 80 - 18^2} = -1,1184$$

$$b_0 = \bar{y} - b_1 \bar{x} = 5 - (-1,1184) \times 3,6 = 9,0263$$



ANÁLISE DE REGRESSÃO

Gráfico de dispersão com a reta estimada:





ANÁLISE DE REGRESSÃO

X	Y	$\hat{Y}$
3	5	5.67
1	8	7.91
3	6	5.67
5	4	3.43
6	2	2.32

Os valores ajustados pela reta estão na coluna $\hat{Y}$. Observa-se que estão próximos dos valores verdadeiros de Y , o que indica um bom ajuste.



ANÁLISE DE REGRESSÃO

- As retas de regressão podem ser úteis para prever o valor de uma variável, dado algum valor particular de outra variável.
- Se a reta de regressão se ajusta bem aos dados, então faz sentido usar essa equação para previsões, desde que não ultrapassemos o limite dos valores disponíveis.
- No entanto, devemos usar a reta de regressão para previsões apenas se a equação de regressão for um bom modelo para os dados.



ANÁLISE DE REGRESSÃO

- No exemplo, suponha que desejemos ter ideia do valor da variável Y quando X assume o valor 2.
- Substituindo na reta de regressão estimada, temos:

$$9,0263 - 1,1184 \times 2 = 6,79$$



EXERCÍCIO

Verifique se a associação linear entre as variáveis peso do carro (libra) e consumo de combustível (milha/galão) é forte através do coeficiente de correlação. Ajuste uma reta de regressão para explicar a variável consumo de combustível através do peso do respectivo carro. Interprete as estimativas da reta encontradas

Peso	3175	3450	3225	3985	2440	2500	2290
Consumo	27	29	27	24	37	34	37